


Clasificación de push-ups como correctas e incorrectas



Asignatura: Extensiones de Machine Learning

Grado: Ciencia e Ingeniería de Datos

Curso académico: 2025–2026

Marcos Yordanov Marín

Víctor López Martínez

Universidad y Facultad: Universidad de Murcia - Facultad de Informática

Índice

Introducción	3
Contexto y motivación	3
Objetivos	3
Contribuciones	3
Estado del arte	4
Estimación de pose (pose estimation / keypoint detection)	4
Clasificación basada en esqueletos (skeleton-based action recognition)	5
Metodología	6
Descripción y Adquisición del Dataset	6
Extracción y Procesamiento de Landmarks (Pose Estimation)	6
Preprocesado y Limpieza de Secuencias	6
Representación de Entrada y Arquitecturas	7
Entrenamiento y Estrategia de Segregación de Datos	8
Evaluación Experimental y Análisis	8
Experimentos	9
Descripción de Objetivos Experimentales	9
A. Establecimiento de la Línea Base (Baseline)	9
B. Exploración de Modelos Recurrentes (RNNs)	9
C. Modelado Espacio-Temporal Avanzado (Grafos)	10
D. Evaluación de Robustez (Data Augmentation)	10
Resultados y discusión	12
A. Establecimiento de la Línea Base (Baseline)	12
B. Exploración de Modelos Recurrentes (RNNs)	12
C. Resultados con un Modelado Espacio-Temporal Avanzado (ST-GCN)	15
D. Evaluación de Robustez (Data Augmentation)	16
Conclusiones y trabajos futuros	17
Referencias	18

Introducción

Contexto y motivación

En los últimos años, la intersección entre la visión por computador y el aprendizaje automático ha permitido el desarrollo de sistemas capaces de interpretar el movimiento humano a partir de vídeo. Estas tecnologías encuentran aplicación en ámbitos tan diversos como la rehabilitación, el deporte, la interacción humano-máquina y el análisis del rendimiento físico. El presente trabajo aborda el problema de la clasificación automática de la ejecución de flexiones de brazos (push-ups) a partir de secuencias de vídeo, con el objetivo de distinguir entre ejecuciones correctas e incorrectas. Este problema es relevante para entrenadores personales, aplicaciones de fitness virtual y plataformas de tele-rehabilitación que requieren retroalimentación automática y en tiempo real.

Los enfoques actuales que analizan técnica y postura suelen basarse en sensores corporales o en la intervención manual de un experto. Las soluciones basadas únicamente en vídeo ofrecen la ventaja de ser no invasivas y fáciles de desplegar, pero presentan retos adicionales: detección robusta de puntos clave (landmarks) ante oclusiones y cambios de perspectiva, manejo de frames con detecciones ausentes o ruidos, y diseño de modelos que capten la dinámica temporal de un ejercicio. En este proyecto se propone un pipeline completo que incluye: extracción y normalización de landmarks con MediaPipe, preprocesado para manejar secuencias de longitud variable y frames nulos (padding/masking o interpolación), y la construcción y evaluación de modelos de clasificación temporal (p. ej. RNNs como LSTM o Bidirectional LSTM) adaptados a la tarea.

Objetivos

- Diseñar e implementar un pipeline reproducible para la extracción de landmarks de flexiones de vídeo y su preprocesado (padding, identificación de frames vacíos, enmascarado).
- Explorar y comparar arquitecturas para modelar la dinámica temporal y clasificar la ejecución (correcta vs. incorrecta).
- Evaluar la robustez del sistema frente a variaciones en la cámara..
- Generar una herramienta demostrativa (scripts / notebook) que facilite la inspección visual de resultados y la creación reproducible del dataset procesado.

Contribuciones

- Desarrollo de una colección procesada de secuencias de landmarks (formato estandarizado, padding consistente) preparada para experimentación.
- Implementación de utilidades prácticas para análisis exploratorio: detección de frames con todas las coordenadas a 0, conteo de rachas consecutivas de frames inválidos, funciones para visualizar landmarks sobre frames y extraer frames del vídeo.
- Diseño experimental que compara varias estrategias de tratamiento de datos faltantes (eliminación, interpolación, masking) y varias arquitecturas de clasificación, con métricas cuantitativas y análisis cualitativo de errores.
- Repositorio reproducible con notebooks, ejemplos de visualización y scripts para replicar experimentos.

Estado del arte

El Estado del Arte resume las líneas principales de investigación y técnicas utilizadas para detectar y analizar la ejecución de ejercicios desde vídeo. Aquí nos centramos en: (1) estimación de pose / extracción de landmarks, (2) reconocimiento de acciones o clasificación desde secuencias temporales de puntos clave (skeleton-based action recognition).

Estimación de pose (pose estimation / keypoint detection)

Concepto Básico

La estimación de pose es un conjunto de técnicas que identifican las coordenadas (usualmente normalizadas o en píxeles absolutos) de puntos clave (*landmarks*) del cuerpo en imágenes o video. Estos métodos suelen generar, además de las coordenadas (x, y), una puntuación de visibilidad o confianza para cada punto.

Evolución y Enfoques Clave

- **OpenPose (Cao et al., 2017):** Fue pionero en arquitecturas para la detección multi-persona y popularizó el uso de mapas de calor (*heatmaps*), demostrando solidez en escenarios complejos.
- **Modelos de Alto Rendimiento (Sun, Ke et al., 2019):** Soluciones más recientes (como HRNet, AlphaPose) han logrado avances significativos, aumentando la resolución espacial y la precisión, incluso con poses corporales difíciles.
- **Soluciones Ligeras y de Tiempo Real (MediaPipe):** Desarrollos como MediaPipe (Google) se han convertido en la opción preferida para prototipos y aplicaciones en tiempo real. Ofrecen detección de baja latencia con *outputs* directos (x, y, confianza/visibilidad).

Relevancia para el Proyecto

La precisión en la clasificación de flexiones (push-ups) depende intrínsecamente de la calidad de los *landmarks* detectados. Es crucial manejar de manera efectiva factores como las oclusiones, la ausencia de detección de ciertos puntos y la gestión de la confianza asignada a cada *keypoint*.

Clasificación basada en esqueletos (skeleton-based action recognition)

Concepto Central:

En lugar de procesar directamente los píxeles de una imagen o video, la entrada a estos modelos se compone de secuencias de las posiciones de los puntos clave (esqueleto humano). Esta aproximación ofrece ventajas significativas como la reducción de ruido, una menor demanda de datos de entrenamiento y una mayor facilidad para interpretar los resultados.

Principales Técnicas Empleadas:

- Modelos Recurrentes (RNN, LSTM, GRU):**
 - Fueron de las primeras arquitecturas adoptadas para el análisis de datos secuenciales de *keypoints*, dada su capacidad intrínseca para capturar las dependencias temporales dentro de las secuencias.
- Redes Convolucionales Temporales (TCN, 1D-CNN temporal):**
 - Procesan las secuencias de manera eficiente para identificar patrones temporales. Destacan por su paralelismo y estabilidad durante el entrenamiento.
- Redes Convolucionales Gráficas (GCN) Espacio-Temporales (Yan, Sijie et al., 2018, #):**
 - Modelan la estructura del esqueleto como un grafo, donde los nodos son los *keypoints* y las aristas representan conexiones anatómicas y temporales. Han demostrado ser muy robustas en conjuntos de datos de acciones humanas.
- Transformers y Mecanismos de Atención Temporal:**
 - Arquitecturas recientes, incluyendo variantes como Video Transformers y *pose-aware* Transformers, han probado su gran eficacia para modelar relaciones y dependencias a largo plazo dentro de las secuencias.

Ventajas e Inconvenientes de los Métodos de Clasificación de Flexiones

Método	Ventajas	Inconvenientes
Basados en Esqueleto (<i>Skeleton-based</i>)	Eficientes y robustos frente a variaciones de fondo.	Dependen de la calidad de los puntos clave (<i>keypoints</i>) y tienden a perder información de textura/contexto.
Basados en Píxeles (<i>Pixel-based</i>) (C3D, I3D, <i>Two-Stream</i>)	Conservan toda la información visual.	Requieren más datos y mayor capacidad de cálculo.

Metodología

Descripción y Adquisición del *Dataset*

Hemos obtenido el dataset con los vídeos de la página [kaggle.com](https://www.kaggle.com) (Shraf Salama, 2022).

En dicho conjunto, varias personas ejecutan flexiones clasificadas en dos categorías:

- **Flexiones con técnica correcta**
- **Flexiones con técnica incorrecta**
(ejemplos incluyen: abducción excesiva de los codos, descenso de la cadera, recorrido de movimiento incompleto, entre otros).

La representación de la información se realiza mediante el procesamiento de cada vídeo para extraer una secuencia temporal de *landmarks*. Específicamente, se obtienen 33 *landmarks* de pose por cada *frame*, con sus coordenadas (x, y) normalizadas. Estos 66 valores por *frame* se aplanan para formar vectores de entrada. Para estandarizar las secuencias para el modelado, se aplica un proceso de normalización de longitud fija, utilizando *padding* (relleno con ceros) o truncamiento para alcanzar una longitud preestablecida, por ejemplo, entre 150 y 200 *frames*.

Extracción y Procesamiento de *Landmarks* (Pose Estimation)

La detección de pose se lleva a cabo utilizando **MediaPipe Pose**. Esta herramienta fue seleccionada por su eficiencia en la extracción en tiempo real y por proporcionar 33 *landmarks* con coordenadas normalizadas y una puntuación de visibilidad.

El procesamiento se realiza *frame a frame*. Si la herramienta no detecta una pose en un *frame* concreto, la fila de datos correspondiente se rellena con 66 ceros. Se mantiene un registro detallado de los *frames* sin detección para un análisis posterior de secuencias potencialmente corruptas. Finalmente, las secuencias de *landmarks* extraídas se guardan en disco, junto con metainformación como el número de *frames* y los FPS, asegurando la reproducibilidad del proceso.

Preprocesado y Limpieza de Secuencias

La fase de preprocesado es crucial para preparar los datos para la entrada a los modelos de aprendizaje profundo.

Aplanado y *Padding*

Cada *frame* de 33 *landmarks* con 2 coordenadas (33, 2) se convierte en un vector aplanado de 66 valores (66,). Se establece una longitud máxima (p. ej., 200 *frames*). Las secuencias más cortas se rellenan con ceros (*padding*) y las más largas se truncan o se muestrean. Es esencial generar una **máscara binaria** que indique qué *frames* son válidos (1) y cuáles corresponden a *padding* o datos faltantes (0). Tratamiento de Datos Faltantes

Se identifican los *frames* donde todos los puntos de *landmark* son cero. Si estas rachas de ceros son cortas, se contempla la **interpolación temporal** (esta estrategia finalmente no fue necesaria al comprobar que no existían datos faltantes a lo largo de la secuencia válida). No obstante, la estrategia preferente es utilizar la **máscara binaria** en la entrada del modelo, permitiendo que arquitecturas como las capas de *Masking* o mecanismos de atención gestionen la información faltante.

Normalización Espacial

Aunque las coordenadas de los *landmarks* ya están normalizadas en el rango $[0, 1]$, se exploran normalizaciones relativas para dotar de invarianza de escala y posición a los datos. Esto incluye el recentrado con respecto a un punto base (p. ej., la cadera) o el escalado por la distancia entre dos puntos anatómicos (p. ej., hombro-cadera). Ambos formatos (el *raw normalized* y el *centered/scale normalized*) se conservan para realizar experimentos comparativos. Aumento de Datos (*Augmentation*)

Para mejorar la robustez del modelo, se aplica un *data augmentation* de las secuencias, incluyendo: adición de ruido gaussiano a las coordenadas, rotaciones y traslaciones leves, y *dropout* de puntos clave para simular fallos en la detección.

Representación de Entrada y Arquitecturas

La representación final de entrada se establece como un *array* de forma $(L_{max}, 66)$.

Como alternativa, se propone el uso de ángulos articulares calculados a partir de los landmarks de las secuencias.

Arquitecturas Propuestas.

Se consideran distintas arquitecturas para el modelado temporal de las secuencias:

- **Baseline:** Se implementará un *pipeline* inicial simple que incluirá una pila de 1D-CNN, seguida de capas densas con activación *Sigmoid* para la clasificación binaria.
- **Modelos Recurrentes:** Se implementarán redes **LSTM o GRU** y sus versiones **bidireccionales** (1 a 3 capas con *dropout*).
- **Modelo Híbrido Avanzado:** Se explorará con el uso de **ST-GCN (*Spatial-Temporal Graph Convolutional Networks*)**, que modelan el esqueleto como un grafo.




Figure 1: Overview of the ST-GCN Architecture with Masked Pooling for Action Recognition

Entrenamiento y Estrategia de Segregación de Datos

Segregación de datos

Se empleará la validación cruzada K-fold con $k = 5$. Esta estrategia se considera ideal al disponer de pocas muestras, ya que mitiga la posibilidad de que una muestra ruidosa o de mala calidad caiga en el conjunto de validación (lo cual podría ocurrir al usar el método de segregación hold-out) y afecte de forma muy negativa a la valoración del modelo.

Hiperparámetros y Regularización

Los modelos se entrenarán con tamaños de *batch* de 32 a 128, utilizando el optimizador **Adam** con un *learning rate* entre 10^{-3} y 10^{-4} . Se aplicará *early stopping* (p. ej., paciencia de 10-20 épocas) para evitar el sobreajuste. La regularización incluirá *dropout* (0.2–0.5) en las capas densas y el uso del *data augmentation* de secuencias.

Función de pérdida

Nuestra función de pérdida será el Binary Crossentropy (entropía cruzada binaria), ya que es la opción más idónea para un clasificador binario.

$$\mathcal{L} = - \frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

Métricas de Evaluación

Dado que trataremos un dataset balanceado (mismo porcentaje de muestras de la clase positiva y negativas), no analizaremos métricas como el F1-Score. La métrica principal será el **Accuracy**. Como método adicional, se realizará un análisis de matrices de confusión para entender los errores del modelo y la clasificación por subtipos de error.

Evaluación Experimental y Análisis

El proceso de evaluación se ha diseñado para comparar el rendimiento de las distintas configuraciones experimentales (representación de datos, arquitecturas de red y estrategias de aumento) con el máximo rigor estadístico posible.

Dada la limitación en el número de muestras disponibles ($N = 100$), el reporte de una única métrica puntual (como la media de los pliegues de la validación cruzada) podría no reflejar adecuadamente la estabilidad del modelo. Por ello, se ha adoptado una estrategia de evaluación basada en *Muestreo Bootstrap no paramétrico*.

Esta metodología consiste en agregar las predicciones obtenidas durante la validación cruzada y someterlas a un proceso de remuestreo con reemplazo (1000 iteraciones). Esto nos permite estimar la distribución empírica del rendimiento y reportar dos indicadores clave para cada experimento:

1. Accuracy Medio (Bootstrap): Una estimación robusta de la esperanza matemática del acierto del modelo.
2. Intervalo de Confianza (IC) al 95%: Un rango de valores (límite inferior y superior) que cuantifica la incertidumbre de la métrica, permitiendo determinar si las diferencias de rendimiento entre modelos son estadísticamente significativas o fruto del azar.

Experimentos

El diseño experimental de este trabajo se estructura en torno a la combinación de diferentes **variables experimentales**, con el objetivo de identificar la configuración que maximice el rendimiento en la clasificación. Estas variables incluyen el preprocesamiento de los datos de entrada (comparando coordenadas crudas frente a cálculos geométricos derivados y el uso de técnicas de aumento de datos), la selección de la arquitectura de red (evaluando modelos de distinta naturaleza y complejidad) y el ajuste de sus hiperparámetros.

Para sistematizar el proceso de validación, se diseñó una matriz de experimentos identificados con un código único (ID Exp). La tabla resume las configuraciones técnicas, el tipo de datos empleados y el objetivo específico de cada prueba realizada.

Descripción de Objetivos Experimentales

A continuación se detalla la motivación y el propósito de cada conjunto de pruebas:

A. Establecimiento de la Línea Base (Baseline)

- **EXP-CNN-01 (Baseline Coordinates):** Implementación de una red convolucional simple (1D-CNN) para establecer el umbral mínimo de rendimiento utilizando las coordenadas crudas (*raw coordinates*) de los *landmarks*.
- **EXP-CNN-02 (Feature Engineering):** Evaluación del impacto del uso de conocimiento experto (ángulos articulares pre-calculados) en arquitecturas simples frente al uso de coordenadas puras.

B. Exploración de Modelos Recurrentes (RNNs)

- **EXP-LSTM-01 y EXP-LSTM-01-deep (Profundidad y Complejidad):** Estudio para determinar la complejidad óptima de la red LSTM. Se compara una arquitectura ligera (1 capa) frente a una más profunda (2 capas) para verificar si el aumento de parámetros mejora la captura de dependencias temporales.

- **EXP-LSTM-02 (Input en RNN):** Verificación de si la simplificación de la entrada (ángulos) beneficia el entrenamiento de redes recurrentes profundas o si, por el contrario, conlleva una pérdida de información espacial crítica.
- **EXP-Bi-LSTM_01 (Contexto Bidireccional):** Implementación de Bi-LSTM para evaluar si el acceso a la información futura de la secuencia (flujo inverso) mejora la clasificación de la técnica. Uso de landmarks (coordenadas en crudo).
- **EXP-Bi-LSTM_02:** Mismo experimento que *EXP-Bi-LSTM_01* pero usando ángulos articulares en lugar de coordenadas en crudo.

C. Modelado Espacio-Temporal Avanzado (Grafos)

- **EXP-ST-GCN-01:** Introducción de las Redes Convolucionales de Grafos Espacio-Temporales para modelar explícitamente la estructura del esqueleto humano, capturando dependencias espaciales y temporales simultáneamente.

D. Evaluación de Robustez (Data Augmentation)

- **EXP-CNN-03, EXP-CNN-04, EXP-LSTM-03, EXP-LSTM-04, EXP-Bi-LSTM-03, EXP-Bi-LSTM-04, EXP-ST-GCN-02 (Validación Final):** Replicación de las arquitecturas más prometedoras de cada familia (CNN, LSTM, Bi-LSTM y ST-GCN) utilizando el conjunto de datos aumentado (técnica de espejo). El objetivo es medir la capacidad de generalización de los modelos y la reducción del sobreajuste (*overfitting*) al duplicar la variabilidad de las muestras de entrenamiento.

Más detalles de los experimentos en el Jupyter Notebook.


Tabla con todos los experimentos realizados:

ID Exp.	Modelo	Input	Aug ment	Configuración (Arquitectura)	Batch Size	Epochs	Patience	Framework
EXP-CNN-01	CNN-1D	Coords	No	3 layers Conv1D, 64 filters	32	100	35	PyTorch
EXP-CNN-02	CNN-1D	Ángulos	No	3 layers Conv1D, 64 filters	32	100	35	PyTorch
EXP-LSTM-01	LSTM	Coords	No	LSTM(64) → Dense(32) Drop 0.2	16	40	15	TensorFlow
EXP-LSTM-01-deep	LSTM	Coords	No	LSTM(128, 64) → Dense(64, 32) Drop 0.2	16	100	15	TensorFlow
EXP-LSTM-02	LSTM	Ángulos	No	LSTM(64) → Dense(32) Drop 0.2	16	100	15	TensorFlow
EXP-Bi-LSTM-01	Bi-LSTM	Coords	No	LSTM(128, 64) → Dense(64, 32) Drop 0.3	16	120	20	TensorFlow
EXP-Bi-LSTM-02	Bi-LSTM	Ángulos	No	LSTM(128, 64) → Dense(64, 32) Drop 0.3	32	100	20	TensorFlow
EXP-ST-GCN-01	ST-GCN	Coords	No	3 Blocks (K=1), Ch: 64-128	32	100	35	PyTorch
EXP-CNN-03	CNN-1D	Coords	Sí	3 layers Conv1D, 64 filters	32	100	35	PyTorch
EXP-CNN-04	CNN-1D	Ángulos	Sí	3 layers Conv1D, 64 filters	32	100	35	TensorFlow
EXP-LSTM-03	LSTM	Coords	Sí	LSTM(128, 64) → Dense(64, 32) Drop 0.2	16	100	15	TensorFlow
EXP-LSTM-04	LSTM	Ángulos	Sí	LSTM(256, 128) → Dense(64, 32) Drop 0.3	16	80	15	TensorFlow
EXP-Bi-LSTM-03	Bi-LSTM	Coords	Sí	LSTM(128, 64) → Dense(64, 32) Drop 0.25	16	80	10	TensorFlow
EXP-Bi-LSTM-04	Bi-LSTM	Ángulos	Sí	LSTM(128, 64) → Dense(64, 32) Drop 0.3	16	120	20	TensorFlow
EXP-ST-GCN-02	ST-GCN	Coords	Sí	3 Blocks (K=1), Ch: 64-128	16	100	35	PyTorch

Resultados y discusión

A. Establecimiento de la Línea Base (Baseline)

¿Cuáles son las puntuaciones mínimas que podemos alcanzar con el modelo más básico?



Un modelo muy sencillo suele ser capaz de alcanzar un accuracy del 70%. Este umbral nos servirá para valorar más adelante que tan buenos han sido los resultados obtenidos con arquitecturas más complejas. Por otro lado, para este tipo de arquitectura utilizar ángulos articulares (datos calculados a partir de los landmarks) no supone apenas ninguna mejora.

B. Exploración de Modelos Recurrentes (RNNs)

¿Conseguimos mejorar el rendimiento del modelo con LSTMs?


Sí, conseguimos mejorar el rendimiento global con LSTMs, logrando el resultado más alto de todos los experimentos (0.9800 de *Accuracy*). Sin embargo, el grado de mejora depende de si comparamos escenarios con o sin *Data Augmentation*.

En los escenarios sin aumento de datos, las LSTMs y Bi-LSTMs demuestran una clara superioridad frente a las CNNs básicas.

- CNNs (baseline): el mejor modelo (EXP-CNN-02) alcanzó un accuracy de 0.7298
- LSTMs / Bi-LSTMs: el mejor modelo (Bi-LSTM-02) obtuvo un valor de 0.9000


Por tanto, sin técnicas de aumentación y ambas usando ángulos articulares, la capacidad de las redes recurrentes es claramente superior a las CNNs, mejorando la precisión en casi un 17%.

Gráfico comparando los 4 experimentos (alternando LSTM y BiLSTM con datos de coordenadas y de ángulos)



De este gráfico deducimos que el uso de datos de ángulos articulares para entrenar una RNN da mejores resultados que el uso de coordenadas en bruto.

Los resultados con coordenadas de landmarks son 80 % de accuracy o incluso menos, mientras que los modelos que usan ángulos alcanzan un accuracy de entorno al 90%. Comentar que la LSTM-01 obtiene mejores resultados que la versión profunda. Al añadir más capas a una entrada que de por si es ruidosa (coordenadas crudas), la red no aprendió características más abstractas, sino que probablemente sufrió dificultades de convergencia o sobreajuste al ruido. Por otra parte, parece que la Bi-LSTM ha mejorado ligeramente el resultado de la LSTM unidireccional.




Visualmente, las curvas de densidad confirman que en el caso del análisis sin aumento de datos, la LSTM bidireccional obtiene mejores resultados que ambas arquitecturas de redes convolucionales, que se quedaron rondando el 70% de precisión. Observamos que el modelo EXP-Bi-LSTM-02 (con ángulos articulares) alcanzó un valor de aproximadamente 0.9, superando con creces las puntuaciones de los modelos baseline y demostrando que la naturaleza secuencial y direccional de las RNN es superior para la clasificación de movimientos complejos en este contexto.

C. Resultados con un Modelado Espacio-Temporal Avanzado (ST-GCN)

¿Un modelo híbrido avanzado conseguirá mejores puntuaciones que las LSTM?


Gráfico comparando el modelo ST-GCN con el mejor experimento usando RNN (sin aumentación) y los modelos baseline.



La ST-GCN no ha aportado mejores resultados que los ya encontrados. El entrenamiento de este modelo ha supuesto mayores costes computacionales (con uso de GPU) que las anteriores arquitecturas y las diferencias en accuracy respecto al uso de una LSTM simple (entrenada con datos de coordenadas en bruto) son mínimas.

D. Evaluación de Robustez (Data Augmentation)

Comparamos los modelos entrenados con datos originales y con aumentación.



Al analizar el gráfico de barras, salta a la vista que la introducción de la aumentación de datos provoca un salto drástico en el rendimiento, con barras que rozan la perfección y unos intervalos de confianza minúsculos.

Resultados Cuantitativos:

En escenarios con aumento de datos, los modelos alcanzan niveles de precisión muy altos. Aunque los resultados se ajustan, las LSTMs siguen logrando un mejor resultado por un margen pequeño.

- Mejor CNN: el modelo EXP-CN-03, usando coordenadas, logró un valor de accuracy de 0.9701, mejorando en un 32% respecto al mejor modelo CNN base.
- Mejor LSTM: la arquitectura EXP-LSTM-04, usando ángulos articulares, logró una precisión del 98%, el mejor resultado de todo el estudio. Esto representa una mejora del 11% respecto a su versión sin aumento.
- Mejor Bi-LSTM: el modelo EXP-Bi-LSTM-04, usando ángulos articulares también, alcanzó un valor de 0.9701, empatando con la mejor CNN y mejorando casi un 8% respecto a la LSTM bidireccional 02.

Interpretación crítica:

Estos resultados tan idealistas nos generan serias dudas sobre su validez real. A pesar de haber mantenido estrictamente las secuencias aumentadas en el mismo fold que las originales, sospechamos que ha existido una fuga de información: es muy probable que la obtención de landmarks (en vez del uso de imágenes de vídeo) no sea suficiente para enmascarar la 'firma de movimiento' única de cada sujeto. Es posible que los modelos hayan podido identificar a la persona que ejecuta la flexión y clasificarla por memorización de sus movimientos o estilo de ejecución particular, en lugar de aprender las características biomecánicas generales de una buena ejecución.

Conclusiones y trabajos futuros

Los resultados obtenidos son concluyentes y señalan que la configuración más efectiva combina el uso de **ángulos articulares** con un modelo **LSTM bidireccional**. Desde un punto de vista teórico, este resultado es coherente: los ángulos articulares son la característica biomecánica más fiable para determinar la corrección de una postura, mientras que la arquitectura recurrente (LSTM) es ideal para modelar la naturaleza secuencial del ejercicio, analizando cómo evolucionan estos ángulos en el tiempo. Además, el componente bidireccional ha permitido refinar la detección de patrones al procesar la secuencia temporal en ambos sentidos (pasado y futuro), logrando una mayor precisión en la clasificación.

Respecto a la **ST-GCN**, a pesar de ser una arquitectura más avanzada sobre el papel, no ha resultado ser la opción más eficiente en nuestro caso. Si bien utilizamos una configuración básica para establecer una línea base, observamos que el coste computacional fue considerablemente mayor —haciendo indispensable el uso de GPU— sin ofrecer una mejora significativa en las métricas respecto a modelos más sencillos. Por tanto, consideramos que su complejidad no compensa el rendimiento obtenido en comparación con las arquitecturas recurrentes.

El principal desafío lo hemos encontrado en la **aumentación de datos**. Dada la limitación de nuestro dataset original, recurrimos a técnicas de espejado (*mirroring*) para ampliar la muestra. Sin embargo, sospechamos que esto ha podido generar un problema de **fuga de datos** (*data leakage*) debido a la escasa diversidad de sujetos. Es muy probable que el modelo haya aprendido patrones de movimiento específicos de cada individuo, llegando a "identificar" a la persona a través de sus *landmarks* y memorizando si ese sujeto en concreto hacía bien o mal la flexión, en lugar de evaluar la técnica del movimiento en sí.

Como **líneas de trabajo futuro**, sería interesante realizar experimentos específicos para comprobar si estas arquitecturas están, efectivamente, clasificando identidades en lugar de acciones, lo cual confirmaría nuestra hipótesis sobre el sesgo. Para mitigar este problema en próximas iteraciones, sería imprescindible ampliar la base de datos con una mayor diversidad de participantes y asegurar que los mismos sujetos realicen tanto ejecuciones correctas como incorrectas, obligando así al modelo a fijarse en la biomecánica y no en la persona.

Referencias

- Cao, Zhe, Simon, Tomas, Wei, Shih-En, & Sheikh, Yaser. (2017). Realtime multi-person 2D pose estimation using part affinity fields. <https://arxiv.org/abs/1611.08050>
- Shraf Salama, M. (2022). LSTM Exercise Classification: Push Up Videos. Retrieved diciembre 2, 2025, from <https://www.kaggle.com/datasets/mohamardashrafsalama/pushup/data>.
- Sun, Ke, Xiao, Bin, Liu, Dong, & Wang, Jingdong. (2019). Deep high-resolution representation learning for human pose estimation. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- Yan, Sijie, Xiong, Yuanjun, & Lin, Dahua. (2018). Spatial temporal graph convolutional networks for skeleton-based action recognition.